Augsburg 多传感器融合与模态缺失鲁棒性实验 MSH-Net 复现与随机模态丢弃扩展

多传感器融合课程项目组
公开匿名版
Augsburg HSI + SAR + DSM

贡献声明与排序 按署名顺序列示本次交付与答辩责任。

1 成员 A 项目统筹、代码与环境复核、实验协议及最终材料整合。
2 成员 B 数据与基线核查、缺失及噪声实验分析、图表与结果复核。
3 成员 C 文献与论文对照、消融分析、演示与复现文档整理。

摘 要—面向传感器缺失条件下的遥感地物分类，本作业在 Augsburg 高光谱、合成孔径雷达与数字表面模型数据上，构建单模态、简单融合、跨模态知识蒸馏与随机模态丢弃特征融合的统一实验。使用 608 个训练点、153 个验证点及 77533 个官方测试点，在 24 GB 统一内存的 Apple Silicon 环境完成 18 个训练阶段和 82 个测试条件。完整模态教师的总体准确率达 91.69%，较最佳单模态基线提高 2.41 个百分点。随机模态丢弃扩展在仅保留 SAR 与 DSM 时达到 82.27%，较普通教师提高 75.45 个百分点；在仅保留 HSI 时达到 91.12%。噪声实验中，SAR 学生在标准差 0.10 的扰动下较单模态基线提高 11.45 个百分点。结果表明，多源融合、缺失模式训练及跨模态蒸馏可在相应条件下发挥互补作用。报告结合消融、类别误差与原论文对照分析这些收益的适用条件，并提供逐样本结果、锁定环境及复现命令。

关键词—多传感器融合，模态缺失，知识蒸馏，随机模态丢弃，遥感分类，可复现

TABLE I
类别与样本数量；测试类别顺序与原论文表 II 一致

类别	训练	验证	测试
森林	117	29	13361
住宅区	211	53	30065
工业区	17	4	3830
低矮植被	198	50	26609
园圃	41	11	523
商业区	6	1	1638
水体	18	5	1507
合计	608	153	77533

I. 问题背景与项目目标

遥感地物分类可以同时利用光谱、散射和高度信息。高光谱影像（HSI）具有丰富的光谱通道，合成孔径雷达（SAR）提供与散射特性相关的观测，数字表面模型（DSM）描述地表高度结构。不同来源之间既有互补性，也存在分布、通道数和噪声特性的差异。多模态学习涉及表征、对齐、融合与协同学习等问题，早期与晚期融合只是其中的不同实现路径 [1]。多源基准及共享、特有特征学习研究为评估这种互补性提供了公开数据条件 [2]。完整输入上的准确率无法回答部署时某一来源失效的问题，因此融合收益与缺失适应能力需要分开检验。

MSH-Net 通过完整模态教师向单输入学生传递知识，并将学生与常规单模态网络的输出融合 [3]。其核心动机是利用训练阶段存在而推理阶段缺失的信息。一般知识蒸馏通过教师的软输出指导学生 [4]；跨模态蒸馏进一步将这种指导用于传感器可用性不同的训练与测试场景，Garcia 等在 RGB 与深度动作识别上研究了训练期多模态、测试期单模态的幻觉网络 [5]。教师只参与训练与蒸馏，最终部署模型仍可仅接收一种可用模态。该方案适合作为课程复现对象，但复现不应只比较运行是否成功，也应检查模型相对单模态基线是否有额外收益，以及收益是否依赖评价指标。

本作业围绕三个可检验问题展开：完整数据条件下，多模态特征融合是否优于单传感器与简单融合；当测试输入缺失时，专门训练的单输入网络是否优于直接对完整输入模型做零填充；蒸馏和输出融合是否在干净输入、噪声输入与各类别上都产生一致改善。为形成自己的课程技术改动，在相同多分支融合结构中引入样本级随机模态丢弃训练。该改动借鉴 ModDrop 的随机丢弃思想 [6]，并适配到本作业的三源分类流程，不作为新的学术算法提出。

项目交付包含技术报告、总结演示、公开代码仓库、数据获取脚本、小样本演示以及正式实验结果。正式评估范围为 Augsburg 三模态、训练 seed 为 42 的实验。其他模态组合的运行入口供后续复用，未列入本次结果；环境检查仅验证流程，不作为正式性能。

II. 数据、任务与评价协议

A. 数据来源与模态

Augsburg 来自公开的 S2FL 基准 [2], [7]。对齐后的三种输入具有相同的 332×485 空间尺寸：HSI 含 180 个通道，SAR 含 4 个特征通道，DSM 含 1 个通道。DSM 是高度表征而非普通可见光图像。本文将三者记为 $\mathcal{M} = \{H, S, D\}$，任务是根据以待分类像素为中心的局部邻域，预测七类地物之一。图1显示三个来源的可视化，图像仅用于说明输入差异，不改变网络实际使用的通道。

官方标注包含 761 个训练点和 77533 个测试点。本文从官方训练点按类别分层抽取 20% 作为内部验证集，固定划分 seed 为 2026，得到 608 个训练点和 153 个验证点。表I列出各类别数量。所有方法使用相同划分，官方测试集在本次请求的模型训练与选择完成后才读取。该协议没有再使用训练与验证点进行全量重训，因此与论文使用 761 个训练点的设置不同。

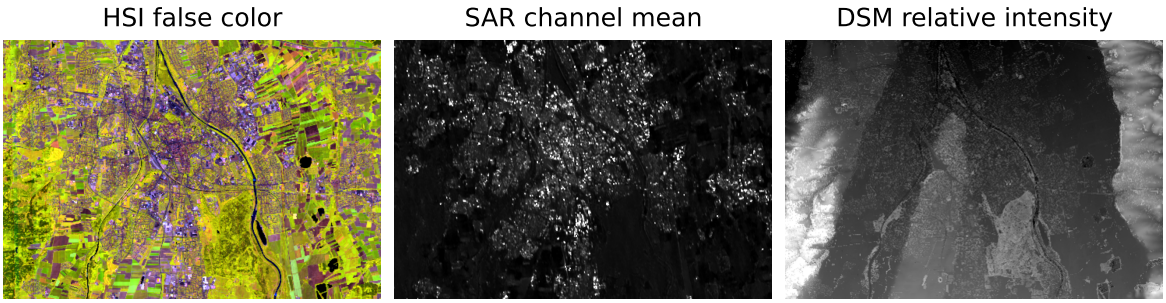


Fig. 1. Augsburg 输入来源。HSI 为索引 70、40、20（从 0 开始）通道的假彩色显示，SAR 为四通道均值，DSM 为相对强度。每幅图按 1% 与 99% 分位拉伸，仅影响显示；网络仍使用逐波段归一化的全部通道。

B. 预处理与输入构造

输入为 7×7 邻域。每个模态按整幅场景逐波段进行最小值–最大值归一化，常量波段的分母置为 1。边界坐标采用重复边界取样。该设置沿用作者预处理约定，利用了未标注场景的范围统计，不能称为仅由训练点估计的归一化。Augsburg 测试 HSI 按需裁剪邻域，避免加载约 4.54 GB 的展开测试矩阵。此前逐一比较了三模态各 761 个作者训练 patch，float32 最大绝对差为 0，标签顺序也一致。

训练、验证中心索引没有重复，但随机点划分不具有空间隔离性。坐标审计发现 153 个验证点全部处于某个训练点的 Chebyshev 距离 3 以内，其中 148 个在距离 1 以内。因此其 7×7 邻域均与训练邻域重叠。对具有空间依赖的数据，随机划分可能低估独立区域上的预测误差，空间分块是文献讨论的一种评价策略 [8]。本文将内部验证用于一致的模型选择，但不把接近 100% 的验证准确率解释为空间独立区域的泛化能力。

C. 评价指标

总体准确率 OA 是全部正确分类像素占比。类别平均准确率 AA 在本任务中取七类召回率的等权平均。设混淆矩阵为 C，总样本数为 N，有

$$\mathrm{OA} = \frac{\sum_c C_{cc}}{N}, \qquad \mathrm{AA} = \frac{1}{7}\sum_{c=1}^{7} \frac{C_{cc}}{\sum_j C_{cj}}. \tag{1}$$

Kappa 为 $(p_o - p_e)/(1 - p_e)$，其中 $p_o = \mathrm{OA}$，p_e 由预测和真实类别边际频率计算。OA、AA 以百分数报告，差异用百分点表示；Kappa 以 0 至 1 的量纲保存。论文表格 Ka 采用 0 至 100 显示，比较时统一换算。

III. 融合方法与课程扩展

A. 单模态与简单融合基线

单模态基线分别使用 HSI、SAR 或 DSM，采用作者单分支网络和交叉熵训练。输入级简单融合将所有模态沿通道维拼接，再送入同类单分支网络。决策级简单融合分别训练各模态分类器，测试时对类别概率等权平均。完整模态教师采用作者的多分支跨模态特征融合网络。上述方法覆盖输入、特征和决策三个融合层次。Hong 等系统比较了遥感中的多种融合架构及跨模态学习设置 [9]，为本作业从简单基线到多分支特征融合的比较提供了方法背景。

对于完整模态训练的模型，缺失输入在归一化空间置为全零，保持其他输入不变，不针对测试子集重新训练。概率平均基线也保留全部分支，缺失分支读取零输入，因此它不同于只平均可用分支的方案。此定义解释了其仅保留 HSI 时为何不能退化为 HSI 单模型的性能。

B. JAD 蒸馏与共享、特有信息融合

完整模态教师输出 logits z_t 和特征 f_t。单输入学生只接收可用模态 x_v，输出 z_s, f_s。教师在蒸馏阶段冻结，学生损失为

$$L_s = L_{\mathrm{CE}}(z_s, y) + \alpha L_{\mathrm{MMD}}(f_s, f_t) + \beta T^2 D_{\mathrm{KL}}(p_t^T \| p_s^T), \tag{2}$$

其中 $p^T = \mathrm{softmax}(z/T)$，温度 $T = 2$。MMD 衡量再生核 Hilbert 空间中分布均值嵌入的差异 [10]。本作业通过多核高斯核匹配特征分布，不要求恢复缺失传感器的真实观测；KL 匹配软化后的输出分布。HSI 学生取 $(\alpha, \beta) = (2, 1)$，SAR 和 DSM 学生取 $(1, 5)$，与论文三模态参数说明一致。

本地实现将 MMD 中显式的 $N \times N \times d$ 距离展开改为平方范数与矩阵乘法，以降低统一内存占用；保留原核形式，并对带宽下界做数值保护。CPU float64 下对原损失及梯度的等价性检查已通过。该优化改变中间计算的内存需求，不引入新的教师信息或标签。

最终 MSH 将 JAD 学生与对应常规单模态分支组合：

$$z = (1 - \eta) z_h + \eta z_n, \qquad \eta = \sigma(a). \tag{3}$$

BatchNorm 使用训练批次统计和推理期运行统计 [11]。本阶段冻结两分支特征提取器及 BatchNorm 统计，仅训练分类头和标量 a，使冻结分支的特征分布保持稳定。两分支都接收同一种可用模态，教师不进入部署检查点。每种可用模态分别训练学生及 MSH，本文没有实现保留两个输入的 MSH 学生。式(3)遵循论文单权重形式，但 sigmoid 约束与初始等权不等于作者发布代码中初始为 1 和 0 的两个自由权重，此差异在复现讨论中保留。

C. 随机模态丢弃特征融合扩展

Dropout 通过随机丢弃网络单元缓解共同适应 [12]，ModDrop 则将随机丢弃用于模态通道及其融合 [6]。本作业的技术改动保持教师的多分支特征融合结构，在训练输入上加入样本级模态掩码。设 $m = (m_H, m_S, m_D)$，以概率 0.5 保留完整输入，以剩余概率均匀选一个模态置零，即每个单模态丢弃掩码的概率为 $1/6$。目标为

$$\min_{\theta} \ \mathbb{E}_{(x,y),m} L_{\mathrm{CE}}\big(F_\theta(m_H x_H, m_S x_S, m_D x_D), y\big). \tag{4}$$

该实现称为 ModDrop 扩展。其融合发生于各模态编码后的特征层，训练改动让网络直接接触缺失条件，测试不需额外教师。它借鉴已有随机模态丢弃思想 [6]，本作业贡献是与公开三模态网络、缺失协议及 Mac 复现流程结合，而非提出原始 ModDrop 算法。训练只覆盖完整与缺一个模态，测试仍包括缺两个模态，这种掩码分布差异需要在分析中说明。

IV. 实验设计与实现

A. 正式训练设置

实验使用 macOS arm64、Python 3.11.14、PyTorch 2.5.1 和 MPS。依赖由 uv 锁定。训练 batch 为 32，SGD 学习率 10^{-3}、动量 0.9、weight decay 为 10^{-3}，采用 5 epoch 线性 warmup 和随后 cosine 衰减。教师、单模态、学生、损失消融和 ModDrop 各训练 500 epoch，最终融合 100 epoch。每阶段以验证 OA 优先、验证 CE 打破平局选取 best，last 保存模型、优化器与历史以支持 epoch 边界恢复。

运行 seed 为 42，划分 seed 固定为 2026。作者构造器内部保留固定初始化 seed，本地阶段按实验名与运行 seed 设定训练随机顺序。因此即使后续增加运行 seed，也不能自动称为不同独立随机初始化。本批没有运行 seed43 和 44 的正式证据，不报告跨 seed 标准差、显著性或置信区间。

B. 实验矩阵

核心实验包含三种单模态基线、输入拼接、概率平均、教师、三个 JAD 学生和三个 MSH 模型。拼接、平均和教师均测试七个非空输入子集，其余方法测试对应的单输入条件，共 30 条核心记录。扩展包含 ModDrop 的七种输入、六个 KL-only 或 MMD-only 学生、三个测试时固定 $\eta = 0.5$ 的干预，以及四类单输入方法在三档非零噪声下的 36 条记录，总计 82 个测试条件、18 个独立训练阶段。

KL-only 将式(2)的 α 置零，MMD-only 将 β 置零，其余配置保持对应设定。它们是学生级损失对照，没有再分别训练最终融合网络。不同实验名对应不同训练批次顺序，因此本次单 seed 消融提供趋势证据，不构成严格控制批次随机性的因果结论。固定 η 实验复用已有分类头，只在测试时改权重，不能替代从头固定权重训练。

C. 缺失与噪声量化

三模态完整输入、三个缺一模态组合和三个缺两模态组合共同覆盖七种非空输入。噪声实验向可用的归一化输入加入独立高斯噪声，标准差为 0.05、0.10、0.20，并截断到 $[0, 1]$。相同形状输入使用固定噪声实现，以便对照。该扰动不等同于实际传感器经标定后的误差分布，也不把标准差 0.2 解释为真实仪器 20% 噪声。没有训练噪声增强，也没有噪声随机重复，因此结论限定于当前扰动实现。

V. 实验结果与分析

A. 完整模态与单输入主结果

表II列出主要干净输入结果。教师完整模态 OA 为 91.69%，比 HSI 单模态 89.29% 高 2.41 个百分点，支持多源信息的互补价值。但输入拼接已经达到 91.54%，仅比教师低 0.15 个百分点，且 AA 为 68.20%，高于教师 66.78%。这说明在当前协议下，复杂特征融合没有展示相对简单拼接的明确全面优势。概率等权平均 OA 为 88.85%，低于 HSI 基线，说明引入较弱分支不保证改善整体分类。

TABLE II
主要干净输入结果；TEACHER、MODDROP、CONCAT、MEAN 使用完整输入，其余使用名称所示单输入

方法/输入	OA (%)	AA (%)	Kappa
SINGLE-HSI	89.29	64.94	0.8458
SINGLE-SAR	81.18	43.62	0.7234
SINGLE-DSM	74.69	43.10	0.6278
EARLY-CONCAT	91.54	68.20	0.8782
LATE-MEAN	88.85	53.71	0.8346
TEACHER	91.69	66.78	0.8802
JAD-HSI	89.38	66.75	0.8480
MSH-HSI	89.59	66.25	0.8506
JAD-SAR	78.67	42.31	0.6870
MSH-SAR	80.48	43.07	0.7127
JAD-DSM	74.24	38.56	0.6177
MSH-DSM	75.41	39.98	0.6344
MODDROP	91.91	65.64	0.8833

TABLE III
不同可用输入下的 OA（%）；缺失输入全零填充

保留输入	拼接	平均	教师	ModDrop
HSI+SAR+DSM	91.54	88.85	91.69	91.91
HSI+SAR	64.79	87.38	83.25	91.69
HSI+DSM	83.62	87.71	55.65	91.41
SAR+DSM	2.87	83.97	6.82	82.27
HSI	40.42	34.32	42.85	91.12
SAR	2.37	68.94	5.97	69.51
DSM	2.76	36.65	9.40	49.29

MSH 仅保留 HSI 时 OA 为 89.59%，比基线高 0.30 个百分点，AA 由 64.94% 增至 66.25%。JAD 学生 AA 为 66.75%，反而高于最终 MSH，表明输出融合在提高一点总体正确率的同时，也可能改变类别间权衡。仅 SAR 时，JAD 的 OA 降至 78.67%，低于基线 81.18%；最终 MSH 回升到 80.48%，但仍低 0.70 个百分点。仅 DSM 时，MSH 的 OA 比基线高 0.72 个百分点，AA 却由 43.10% 降至 39.98%。不能用 OA 的单项提高概括其全部表现。

B. 普通融合模型在缺失输入下的退化

表III展示固定完整输入训练模型的七种测试条件。教师仅保留 HSI、SAR、DSM 时 OA 分别为 42.85%、5.97%、9.40%，明显低于专门训练的对应单输入模型。该现象与论文所讨论的缺失分布偏移方向一致。但普通单模态基线也已经避免崩溃，因此 “MSH 高于零填充教师” 不能独自证明蒸馏的额外价值。

教师保留 HSI+SAR 时 OA83.25%，保留 HSI+DSM 时 55.65%，保留 SAR+DSM 时 6.82%。简单拼接在相应条件下的排序不同，说明缺失性能反映训练后模型依赖以及输入分布变化，不能直接当作传感器固有重要性的排序。概率平均仅 HSI 时 OA34.32%、AA14.29%、Kappa 为 0，预测退化为同一类；此处两个读零输入的分支仍参与平均，与运行 single-HSI 并不矛盾。

TABLE IV
学生损失消融的 OA（%）；MSH 另含最终融合。各阶段仅一个训练 seed，且训练顺序不同

输入	CE	CE+KL	CE+MMD	JAD	MSH
HSI	89.29	89.30	89.41	89.38	89.59
SAR	81.18	80.56	81.25	78.67	80.48
DSM	74.69	71.52	74.49	74.24	75.41

C. 随机模态丢弃扩展的收益与边界

ModDrop 完整输入 OA 为 91.91%，比普通教师高 0.22 个百分点，AA 却低 1.13 个百分点。其主要收益出现在缺失条件：HSI+DSM 由 55.65% 提高至 91.41%，SAR+DSM 由 6.82% 提高至 82.27%，仅 HSI 由 42.85% 提高至 91.12%。训练时引入缺失模式可以显著缓解普通教师的分布偏移，这构成本作业扩展的实证结果。

仅 HSI 时 ModDrop 的 OA 高于 MSH 约 1.53 个百分点，但 AA63.61% 低于 MSH66.25%。仅 SAR 和仅 DSM 时，ModDrop 的 69.51% 和 49.29% 仍低于相应单模态与 MSH。其训练只丢一个模态，缺两个的条件没有直接覆盖，这是可能影响结果的机制之一，尚不能仅凭观测确定为唯一原因。

D. 蒸馏损失消融

表IV显示联合 MMD 与 KL 没有在所有模态上优于单项。HSI 的 MMD-only OA 为 89.41%，略高于 JAD89.38%，但 JAD 的 AA66.75% 高于 MMD-only65.09%。SAR 的 MMD-only 获得 81.25% OA 和 44.56% AA，略优于 CE 基线，而 JAD 降到 78.67% 和 42.31%。DSM 的 KL-only 下降尤为明显，OA 为 71.52%，其余蒸馏学生的 AA 也低于 CE。当前结果提示输出蒸馏可能参与干净精度的负迁移，但教师质量、优化过程和阶段随机顺序也可能影响结果，不能作单一原因归结。

E. 噪声鲁棒性与干净精度的权衡

图3给出噪声曲线。HSI 在标准差 0.05 时，JAD 为 75.10%、MSH 为 69.14%，高于基线 59.46%；标准差 0.20 时则降至 8.63% 和 11.18%，低于基线 12.89%。这说明轻噪声收益不能推广为全部噪声强度下的优势。

SAR 表现出不同权衡：JAD 干净输入 OA 低于基线，但标准差 0.10 时为 63.41%，高于基线 51.96% 共 11.45 个百分点；标准差 0.20 时 54.80% 对 42.83%，高 11.97 个百分点，AA 也更高。最终 MSH 在这些噪声条件下介于学生与基线之间。DSM 的 MSH 在三档噪声下 OA 比基线高约 0.48、1.28、0.93 个百分点，AA 却分别低约 1.06、1.03、1.19 个百分点，类别平均表现仍是其弱点。

F. 融合权重与类别误差

三个 MSH 均在融合 epoch=1 选中 best，其 η 分别约 0.499999、0.499991、0.499978。将测试权重强制设为 0.5，干净输入的三组预测完全不变；十二个干净/噪声对照中，只有 SAR 标准差 0.05 时改变一个像素的预测。最后 epoch 的权重确实有更新，因此不能说没有梯度；但保存用于测试的模型没有显示学习 η 相对近似等权融合的实质收益。该测试干预仍不足以替代固定权重从头训练的对照。

测试集中森林、住宅区和低矮植被占 90.33%，OA 主要受这三类影响。商业区仅有 6 个训练点与 1 个验证点，教师召回率只有 2.44%，MSH-HSI 为 11.11%，低于 HSI 基线 14.41%。MSH-DSM 在住宅区召回率上升约 3.92 个百分点，却在园圃和工业区分别下降约 17.59 和 6.19 个百分点，解释了 OA 提高而 AA 下降。图4给出测试标注位置上的空间结果，未对未标注像素进行补画或平滑。

VI. 论文对照、可比性与局限

A. 与原论文表 VI 的数值关系

表V统一使用原论文表 VI，而非混用正文中不一致的数值。三个 MSH 输入的 OA 比论文分别低 3.40、3.03、6.20 个百分点。单模态基线已经偏低，但在基线之上的 MSH 额外增益也不足：论文 HSI/SAR/DSM 的 OA 增益为 2.08、0.83、3.49 个百分点，本地为 0.30、−0.70、0.72 个百分点。该对照同时呈现本地改善及其与论文结果的幅度差异。

HSI 改善方向与论文一致，但幅度较小。SAR 的 OA 变化方向相反；DSM 虽都有 OA 改善，论文 AA 提高 1.64 个百分点，本地下降 3.12 个百分点。论文的 SAR AA 本身也低于其单模态基线，所以不应将原文概括成所有模态、所有指标全面提高。本地实验展示了完整模态融合的互补收益，以及针对缺失条件训练的实际价值；MSH 在 HSI 与 DSM 上的 OA 改善与论文方向一致。各模态的改善幅度和类别表现存在差异，应结合训练协议解释。

论文三模态正文把 DSM 与 SAR 的 MSH OA 写为 81.86% 和 83.35%，表 VI 则为 81.61% 和 83.51%。本文以视觉核对后的表格为准并重新计算差值，不自行挑选更接近本地的版本。论文表 VII 的蒸馏消融发生于 Houston HSI+LiDAR，且比较对象不同，不能直接作为当前 Augsburg 学生消融的数值目标。ModDrop 和本次高斯噪声扫描也不是表 VI 给出的实验，本文将其作为课程扩展的独立实证结果。

B. 已确认的协议差异

训练点由 761 减为 608，随机翻转增强未在当前正式入口实现，融合初始权重及约束也未完全对齐发布代码。论文正文采用三次运行平均，本地目前只有一个 seed。作者发布脚本每 epoch 在名为 test_loader 的官方测试分区上更新 best，本地改用独立内部验证并在训练后评估官方测试。这些差异改变了训练与选择过程，不能视为等同设置。

本地主要训练阶段已完成 500 epoch，训练 loss 大幅下降，不能简单归因为只训练了几步。缺少翻转是当前实现尚未对齐论文的一项，而非经消融证明可以忽略的选择。MPS 和 CPU 均通过环境与反向传播检查，但现有数据没有分解平台数值差异与协议差异，因此不把所有精度差距归因于 Mac。跨平台运行验证与论文表格对照分别用于检查工程可执行性和实验条件的可比性。

C. 空间验证与统计解释边界

内部验证集较小且邻域重叠，一个验证点改变 OA 约 0.65 个百分点，商业区仅有一个验证点，使模型选择对微小差异和小类表现不敏感。报告披露这些局限，不将高验证 OA 作为独立泛化证据。不同损失阶段的训练顺序不同、噪声只使用固定随机实现，也限制了消融和鲁棒性结论的推广。后续应预先定义更严格的空间划分和配对随机过程，在不反复利用测试集选择的条件下检验改进。

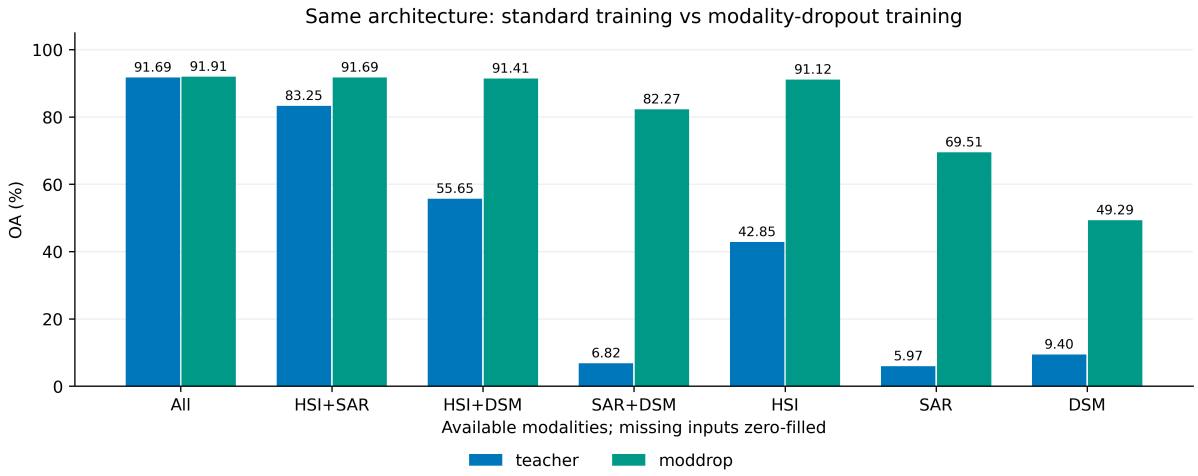


Fig. 2. 相同结构的普通教师与随机模态丢弃扩展。在多种缺失条件下扩展取得更高 OA，但对仅 SAR/DSM 仍不及对应单模态训练。

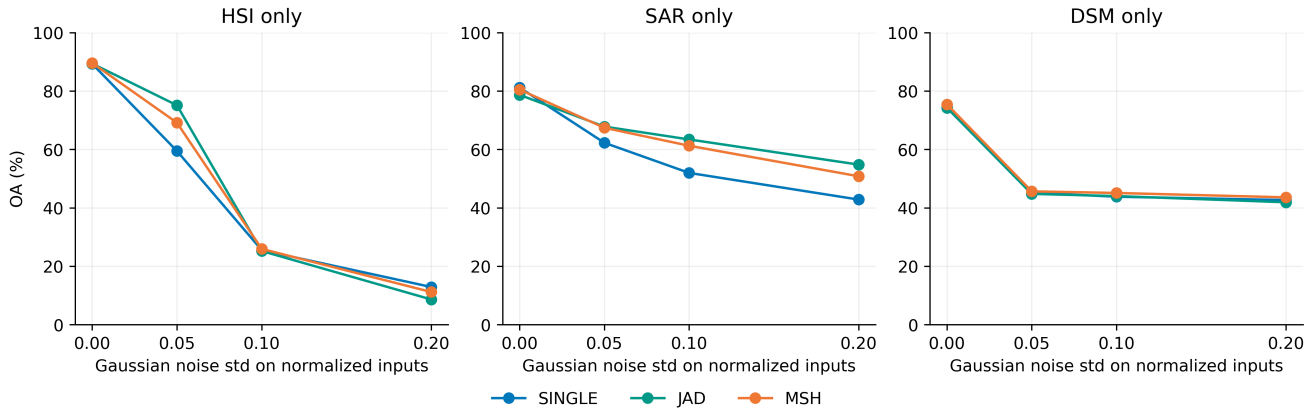


Fig. 3. 单可用模态的高斯噪声实验。横轴为归一化输入上的噪声标准差，纵轴为 OA。所有曲线使用同一官方测试点，未进行噪声训练。

VII. 可复现实现与交付

A. 代码、环境与数据

代码仓库为https://github.com/libo-zhu/sense-course，提供作者网络与 MIT 许可证、上游 commit、Mac 适配、训练推理入口及结果审计脚本。`uv.lock` 锁定依赖；运行 `uv sync --locked` 安装环境，数据由 `scripts/prepare_data.py` 从公开来源下载。原始数据及原论文 PDF 不重新上传，避免把第三方内容混入公开代码。

`mac_demo.py` 用真实数据验证教师、学生、融合、缺失推理及检查点重载；默认每阶段三个更新，仅作流程检查。`run_experiments.py` 负责正式训练，支持自动依赖、epoch 边界恢复和仅评估。完整命令在 README 与提交说明中给出，避免双栏长命令影响复制。

B. 结果追溯与 *Mac* 适配

正式结果按组合与 seed 保存，`models/`提供检查点和历史，`evaluation/`提供指标、逐样本预测与混淆矩阵。混淆矩阵行是真实类、列是预测类，类别从 0 编码。分析脚本逐一复算 82 个条件的 OA、AA、Kappa 并核对原始 TestImage 标签列序；报告、PPT 与 CSV 均使用这批正式结果。

设备显式选择 MPS 或 CPU，结合 MMD 距离优化和测试邻域按需裁剪控制存储。真实数据 demo 的峰值进程 RSS 约 1.34 GiB；完整正式实验已在 24 GB 统一内存设备上完成，但未单独测量完整训练峰值内存。CPU 及原生 MPS 短程检查、冻结状态断言、独立权重推理和 CPU 恢复一致性检查均已通过。部署检查点只含对应单输入模型参数，教师不进入推理流程。

VIII. 结论

本作业在 Augsburg 三模态地物分类上完成了从单传感器、简单融合到知识蒸馏和缺失适配扩展的可复现实验。完整模态教师 OA 达到 91.69%，较最佳单模态提高 2.41 个百分点；随机模态丢弃在 SAR+DSM 条件下达到 82.27%，体现了面向缺失模式训练的实际收益。MSH 在 HSI 与 DSM 上的 OA 有所提高，SAR 学生在中高强度噪声下表现出较强鲁棒性。这些结果为根据输入条件选择融合和蒸馏策略提供了实验依据。

论文表 VI 与本地结果的逐项对照提供了进一步优化的方向：对齐训练点数量与数据增强，完善融合参数和模型选择，并采用空间分块及配对多次实验评估稳定性。后续可扩展随机掩码分布以覆盖仅 SAR 或仅 DSM 的训练条

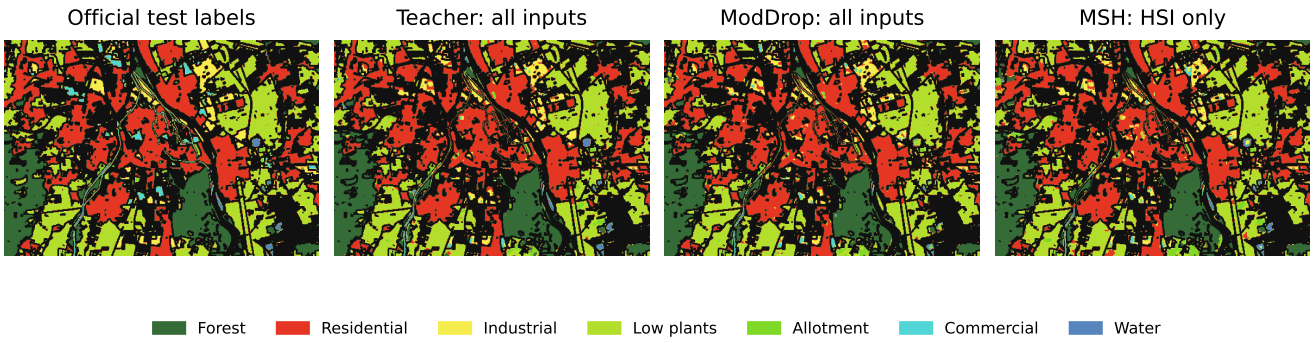


Fig. 4. 官方测试位置的标签与预测。黑色表示非官方测试标注位置，色彩依次对应七类地物；所有方法显示相同像素集合，未用后处理掩盖误差。

TABLE V
与原论文表 VI 的对照；差值为本地减论文，单位为百分点。两者训练协议不同

方法	论文 OA	本地 OA	差值	论文 AA	本地 AA	差值
SINGLE-HSI	90.91	89.29	-1.62	65.32	64.94	-0.38
SINGLE-SAR	82.68	81.18	-1.50	46.12	43.62	-2.50
SINGLE-DSM	78.12	74.69	-3.43	41.96	43.10	+1.14
TEACHER	93.31	91.69	-1.62	63.85	66.78	+2.93
MSH-HSI	92.99	89.59	-3.40	66.86	66.25	-0.61
MSH-SAR	83.51	80.48	-3.03	44.11	43.07	-1.04
MSH-DSM	81.61	75.41	-6.20	43.60	39.98	-3.62

件，并结合类别平衡方法改善小类表现。当前结论限定于已记录的单次运行、数据划分及扰动条件；完整数值与协议差异在正文和代码中保留，便于继续检验和扩展。

参考文献

[1] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, "Multimodal machine learning: A survey and taxonomy," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019.

[2] D. Hong, J. Hu, J. Yao, J. Chanussot, and X. X. Zhu, "Multimodal remote sensing benchmark datasets for land cover classification with a shared and specific feature learning model," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 178, pp. 68–80, 2021.

[3] S. Wei, Y. Luo, X. Ma, P. Ren, and C. Luo, "MSH-Net: Modality-shared hallucination with joint adaptation distillation for remote sensing image classification using missing modalities," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 61, pp. 1–15, 2023, article 4402615.

[4] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," arXiv:1503.02531, 2015. [Online]. Available: https://arxiv.org/abs/1503.02531

[5] N. C. Garcia, P. Morerio, and V. Murino, "Modality distillation with multiple stream networks for action recognition," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 103–118. [Online]. Available: https://openaccess.thecvf.com/content_ECCV_2018/html/Nuno_Garcia_Modality_Distillation_with_ECCV_2018_paper.html

[6] N. Neverova, C. Wolf, G. W. Taylor, and F. Nebout, "ModDrop: Adaptive multi-modal gesture recognition," arXiv:1501.00102v2, 2015. [Online]. Available: https://arxiv.org/abs/1501.00102

[7] D. Hong *et al.*, "ISPRS S2FL: Public code and multimodal benchmark datasets," GitHub repository, accessed: 2026-10-25. [Online]. Available: https://github.com/danfenghong/ISPRS_S2FL

[8] D. R. Roberts, V. Bahn, S. Ciuti, M. S. Boyce, J. Elith, G. Guillera-Arroita, S. Hauenstein, J. J. Lahoz-Monfort, B. Schröder, W. Thuiller, D. I. Warton, B. A. Wintle, F. Hartig, and C. F. Dormann, "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[9] D. Hong, L. Gao, N. Yokoya, J. Yao, J. Chanussot, Q. Du, and B. Zhang, "More diverse means better: Multimodal deep learning meets remote-sensing imagery classification," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 59, no. 5, pp. 4340–4354, 2021.

[10] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, and A. Smola, "A kernel two-sample test," *Journal of Machine Learning Research*, vol. 13, no. 25, pp. 723–773, 2012. [Online]. Available: https://jmlr.org/papers/v13/gretton12a.html

[11] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 37, 2015, pp. 448–456. [Online]. Available: https://proceedings.mlr.press/v37/ioffe15.html

[12] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014. [Online]. Available: https://jmlr.org/papers/v15/srivastava14a.html